

SOUTENANCE DE PROJET DE FIN D'ÉTUDES · SESSION 2026

Automatisation de la numérisation et du traitement des archives foncières par intelligence artificielle

Extraction d'entités manuscrites, contrôle de cohérence et publication ordinale sur Géofoncier

CANDIDAT

Adrien TRAVAILLÉ

Élève-Ingénieur Topographe

ENTREPRISE D'ACCUEIL

Cabinet GEO-SIAPP

Aubenas (Ardèche)

ÉCOLE & CURSUS

INSA Strasbourg

Spécialité Topographie

Sommaire général

Architecture de la soutenance en 5 parties

01

Contexte métier & Cadre juridique

02

État de l'art des technologies documentaires

03

Architecture & Chaîne d'extraction IA

04

Validation des données & Démonstration

05

Bilan, Limites & Déontologie professionnelle

Problématique centrale

Pourquoi ce projet de fin d'études ?

Un fonds volumineux

~23 600 dossiers

- **Archives papier** : Période 1959 à 2007 en cartons
- **Diversité** : Calques, registres manuscrits, DMPC
- **Situation** : Non versées : invisibles pour la profession

Une obligation légale

Article 646 Code civil

- **Monopole légal** : Recherche des antériorités obligatoire
- **Règle constante** : « Bornage sur bornage ne vaut »
- **Primauté** : La limite foncière ancienne prime toujours

Saisie manuelle impossible

25 min / dossier

- **Charge totale** : ~9 800 heures d'opérateur estimées
- **Recherche** : Physique, lente et aléatoire
- **Blocage** : Dossiers inexploités sans outil automatisé

PROBLÉMATIQUE CENTRALE DU PROJET

Dans quelle mesure est-il possible de concevoir un outil logiciel capable d'extraire avec fiabilité les données d'archives foncières très variées, tout en fonctionnant localement sur un ordinateur de bureau ?

Enjeu ordinal national

L'Ordre des Géomètres-Experts estime que plusieurs dizaines de millions de documents dorment dans les archives des cabinets français. La réussite de ce projet ouvre la voie à un déploiement ordinal global.

SOMMAIRE DE LA PARTIE

Contexte métier & Cadre juridique

Cabinet GEO-SIAPP, fonds d'archives et obligations de la profession

1

Structure d'accueil

Le Cabinet GEO-SIAPP et ses 4 agences

2

Cadre juridique

Article 646 et obligation de recherche des antériorités

3

Réalité du fonds

23 600 dossiers papier de 1959 à 2007

4

Le portail Géofoncier

L'enjeu du versement rétrospectif ordinal

Structure d'accueil : Le Cabinet GEO-SIAPP

Implantation territoriale et missions du cabinet géomètre-expert

1.1 Implantation & Activités

- **Siège à Aubenas** : Cabinet fondé en 1992, archives d'agences consolidées depuis 1959.
- **4 agences de proximité** : Aubenas, Pierrelatte, Vallon-Pont-d'Arc, Guilherand-Granges.
- **Activités pluridisciplinaires** : Foncier (bornages, divisions), topographie, urbanisme et VRD.

1992

Création

GEO-SIAPP Aubenas

4

Agences

Ardèche & Drôme

~40 000

Dossiers totaux

Dont 23 600 ciblés

Réseau territorial des 4 agences

Aubenas (Siège social)

Conservation intégrale des archives historiques (23 600 dossiers)

Pierrelatte (Drôme)

Rayonnement sur la Vallée du Rhône et le Sud de la Drôme

Vallon-Pont-d'Arc

Agence Sud-Ardèche : missions foncières et aménagement touristique

Guilherand-Granges

Pôle périurbain de l'agglomération de Valence

Cadre juridique : L'obligation de recherche

Article 646 du Code civil et déontologie de l'Ordre des Géomètres-Experts

1.2 Principes légaux & Déontologie

- **Article 646 du Code civil** : Délimitation contradictoire des propriétés, monopole des géomètres-experts.
- **Règle fondamentale** : « Bornage sur bornage ne vaut » : la limite d'origine prime toujours.
- **Obligation déontologique** : Recherche exhaustive des antériorités avant toute pose de borne.
- **Risque opérationnel** : Responsabilité civile et disciplinaire engagée en cas d'omission.

Bornage contradictoire (Monopole OGE)

- **Fondement légal** : Article 646 du Code civil et Loi du 7 mai 1946.
- **Portée juridique** : Valeur probante définitive, opposable aux tiers et ayants droit.
- **Matérialisation** : Repères physiques inamovibles posés contradictoirement.

La valeur juridique des archives foncières

Un plan de bornage de 1970 conserve une valeur probante supérieure au cadastre actuel. L'accès rapide aux archives anciennes sécurise le droit de propriété.

Cadastre DGFIP (Document fiscal)

- **Vocation première** : Assiette de l'impôt foncier, établi à des fins fiscales.
- **Valeur juridique** : Simple présomption de propriété : ne délimite pas juridiquement.
- **Règle constante** : Le plan cadastral cède toujours devant un bornage contradictoire.

Réalité du fonds : 23 600 dossiers hétérogènes

Cinq fonds de géomètres prédécesseurs, de 1959 à 2007

1.3 Typologie documentaire du fonds

- **Registres manuscrits** : Répertoires chronologiques tenus à la main (1959 à 2007).
- **Formulaires DMPC** : Documents d'Arpentage dactylographiés avec ratures et tampons.
- **Pièces graphiques** : Calques, croquis de terrain, tirages ozalid jaunies et fragiles.


48 ans

D'archives papier
Période 1959-2007

5 fonds

Prédécesseurs rachetés
Aubenas & Privas

Répartition estimée des 23 600 dossiers



Répartition typologique des 23 600 dossiers du cabinet GEO-SIAPP

Le portail Géofoncier : Référentiel national

La plateforme ordinaire de publication des limites foncières

1.4 Plateforme ordinaire nationale

- **Créé en 2010 par l'OGE** : Dépôt obligatoire de tous les dossiers de bornage.
- **Pastilles de bornage** : Emprise parcellaire et métadonnées juridiques publiques.
- **Problème du stock historique** : Les 48 ans d'archives antérieures à 2010 dorment en cartons.
- **Objectif du versement** : Transformer le passif papier en pastilles numériques accessibles.

Le versement rétrospectif

Chaque dossier versé alimente la base nationale et évite les doublons d'arpentage. L'API REST Géofoncier permet d'automatiser ce versement sans saisie manuelle.

Cartographie ordinaire & Validation API



Créer le dossier sur Géofoncier

Annuler / Changer de dossier

Dossier créé avec succès sur Géofoncier ! ID : 19bfe275eb19bd824975d9b0899570d8

Document PDF uploadé avec succès.

Portail Géofoncier avec pastilles de bornage et confirmation de versement API

SOMMAIRE DE LA PARTIE

État de l'art des technologies

Analyse comparative des méthodes de vision, lecture et compréhension de documents

1

Lecture de texte imprimé (OCR)

Tesseract vs approches profondes

2

Reconnaissance d'écriture manuscrite (HTR)

PyLaia vs TrOCR

3

Détection et segmentation spatiale de zones

YOLOv8

4

Extraction d'entités nommées métier

GLiNER Zero-Shot

5

Modèles Vision-Langage (VLM)

Souveraineté locale

6

Extraction de tableaux

Table Transformer et métriques CER/F1

7

Synthèse

L'architecture hybride 4 briques retenue

8

Technologies écartées

Justifications d'exclusion


Lecture de texte imprimé (OCR)

De Tesseract aux réseaux profonds : Baek et al. (2019)

2.1 Principes & Approches OCR

- **Tesseract v5 (Smith, 2007)** : Découpage par lignes et splines polynomiales.
- **Pipeline 4 étapes (Baek, 2019)** : TPS, ResNet, BiLSTM et attention CTC.
- **EasyOCR (Jaided AI, 2021)** : Détection CRAFT et reconnaissance CRNN multi-langues.
- **Binarisation adaptative** : Seuil local par pixel (Sauvola) adapté au papier ancien.

Pipeline OCR 4 étapes (Baek et al., 2019)



Architecture en 4 étapes de Baek et al. (2019)

4 étapes

Pipeline Baek et al.

TPS · ResNet · BiLSTM · CTC

CRAFT

Détection de texte

Réseau EasyOCR

Points clés pour le projet

- Inférence CPU ultra-rapide (< 0,2 s) adaptée aux formulaires dactylographiés.
- Découpage préalable indispensable pour aligner les textes déformés.
- Excellente précision sur chiffres et sections parcellaires imprimées.


Reconnaissance d'écriture manuscrite (HTR)

De PyLaia aux modèles Transformer : TrOCR (Li et al., 2023)

2.2 Écriture manuscrite & Modèles HTR

- **Complexité cursive** : Ligatures, inclinaisons variables et styles individuels des géomètres.
- **PyLaia (Puigcerver, 2017)** : CNN-BiLSTM classique avec fonction CTC, limité sur texte libre.
- **TrOCR (Li et al., 2023)** : Vision Transformer (ViT) couplé à un décodeur textuel RoBERTa.
- **Avantage de TrOCR** : Compréhension sémantique sans segmentation préalable caractère par caractère.

Architecture TrOCR (Li et al., 2023)



ViT

Encodeur d'images
Vision Transformer

RoBERTa

Décodeur linguistique
Modèle de langage français

Points clés pour les archives

- Modèle francophone pré-entraîné très performant sur les écritures soignées.
- Tolérance remarquable aux encres décolorées et variations d'épaisseur.
- Solution retenue pour transcrire les mentions manuscrites des registres.

Détection et segmentation spatiale de zones

Localisation des cartouches, tableaux et signatures : YOLOv8 (Jocher et al., 2023)

2.3 Segmentation monocoup de documents

- **Approche Single-Stage** : Détection directe des boîtes sans découpage préalable.
- **Robustesse documentaire** : Repérage des cartouches et tableaux même raturés.
- **Indépendance textuelle** : Opère sur la géométrie pure, sans dépendre de l'OCR.
- **Efficacité locale** : Modèle Nano léger (< 3,2 M paramètres) exécutable sur GPU bureautique.

Nano (3,2 M)

Paramètres YOLOv8


Vitesse temps réel

< 2 Go GPU

Empreinte mémoire

Inférence bureautique

Détection spatiale YOLOv8 annotée



Détection spatiale des éléments d'un DMPC par YOLO (cartouche, plan, tableau)


Extraction d'entités nommées métier (NER)

GLiNER : extraction d'entités par représentation bidirectionnelle (Zaratiana et al., 2023)

2.4 Repérage Zero-Shot d'entités métier

- **Limites du NER classique** : spaCy et BERT exigent un réentraînement coûteux par classe.
- **Architecture GLiNER** : Bi-encodeur DeBERTa-v3 projetant texte et entités en espace commun.
- **Capacité Zero-Shot** : Extraction immédiate de nouvelles classes par simple invite.
- **Tolérance au bruit OCR** : Reconnaît les entités même avec coquilles de transcription.

Benchmark F1-Score (Zaratiana et al., 2023)



Architecture GLiNER : projection conjointe texte-entités (Zaratiana et al., 2023)

Zero-Shot

Extraction flexible
Sans réentraînement

Bi-encodeur

Texte + Entités
DeBERTa-v3 sous-jacent

Points clés pour le foncier

- DeBERTa surclasse largement BERT (+6 points de F1-Score).
- Détection immédiate des communes, sections, parcelles et dates d'actes.
- Adaptation instantanée aux variations terminologiques des géomètres.


Modèles Vision-Langage (VLM) et souveraineté

Compréhension multimodale locale : MiniCPM-V 2.6 sous Ollama (Liu et al., 2024)

2.5 Compréhension multimodale locale

- **Rôle de secours dans la chaîne** : Sollicité uniquement si TrOCR et GLiNER ont un score insuffisant.
- **Compréhension contextuelle** : Résout les ambiguïtés visuelles : écritures superposées, ratures.
- **Exécution locale 4 bits** : Quantification GGUF permettant de tourner sur GPU bureautique.
- **Souveraineté des données** : Respect strict du secret professionnel : zéro donnée vers des API cloud.

Architecture multimodale VLM (Liu et al., 2024)



Architecture multimodale VLM : projection visuelle vers LLM (Liu et al., 2024)

4-bit local

Quantification GGUF

Exécuté sous Ollama

Zéro Cloud

Souveraineté totale

Secret professionnel OGE

Stratégie de sollicitation

- Activé uniquement en cas de faible confiance GLiNER ($< 0,45$).
- Préserve la cadence globale en évitant les surcoûts d'inférence.
- Déchiffre les toponymes ardéchois ambigus par raisonnement contextuel.

Extraction tabulaire et métriques d'évaluation

Table Transformer (Smock et al., 2021) et critères de performance de la littérature

2.6 Analyse tabulaire & Évaluation

- **Table Transformer (TATR)** : Architecture DETR spécialisée dans les cellules, lignes et colonnes.
- **Défi des registres fonciers** : Absence fréquente de quadrillage imprimé dans les registres anciens.
- **Métriques textuelles** : CER (Character Error Rate) et WER basés sur la distance de Levenshtein.
- **Métriques d'entités** : Précision, Rappel et F1-Score sur les identifiants cadastraux obligatoires.

Table Transformer (Smock et al., 2021)

Table Detection

Table Structure Recognition

Table Functional Analysis

Table Transformer : détection de structure et cellules (Smock et al., 2021)

CER / WER

Distance Levenshtein

Évaluation caractère et mot

F1-Score

Précision & Rappel

Mesure d'entités

Conclusion sur les tableaux

- Heuristiques géométriques retenues pour les registres manuscrits.
- Évaluation rigoureuse sur jeu de test annoté du cabinet.
- Double contrôle par règles métier pour compenser les erreurs tabulaires.

Synthèse de l'état de l'art : L'architecture hybride

Complémentarité des 4 briques retenues pour traiter la diversité du fonds

1. Segmentation spatiale

YOLOv8 Nano (Ultralytics)

- Découpe visuelle des zones : cartouches, tableaux, tampons.
- Géométrie pure sans lecture de texte.
- Empreinte minimale (< 2 Go GPU) et insensibilité aux ratures.

2. Lecture textuelle

EasyOCR + TrOCR francophone

- Double moteur adapté à la typologie de chaque zone.
- EasyOCR pour formulaires imprimés DMPC (CRAFT+CRNN).
- TrOCR pour l'écriture manuscrite cursive (ViT+RoBERTa).

3. Extraction d'entités

GLiNER Zero-Shot (DeBERTa)

- Repérage des métadonnées : commune, section, parcelles, dates.
- Projection vectorielle directe sans réentraînement.
- Définition dynamique des classes par simple consigne.

4. Arbitrage souverain

MiniCPM-V / LLaVA (4-bit)

- Modèle Vision-Langage local exécuté sous Ollama.
- Secours ciblé sur les zones ambiguës ou manuscrites denses.
- Respect strict du secret professionnel : zéro envoi Cloud.

Justification du couplage hybride

Aucun modèle ne traite seul l'ensemble du fonds. L'architecture associe chaque outil sur son domaine d'excellence, en traitement 100 % local et souverain.

Technologies étudiées mais non retenues

Justification technique des choix d'exclusion (Section 3.7 du mémoire)

Tesseract v5 (Smith, 2007)

Moteur OCR classique par caractères

Motif d'exclusion : Analyse caractère par caractère inopérante sur le manuscrit cursif déformé des registres.

LayoutLM / LayoutLMv3 (Xu, 2020)

Modèle multimodal texte-position-image

Motif d'exclusion : Effet domino : dépendance critique envers un OCR initial défaillant sur manuscrit.

Donut (Kim et al., 2022)

Décodage visuel direct sans OCR

Motif d'exclusion : Rigidité aux gabarits prédéfinis, surcoût prohibitif d'annotation de chaque formulaire.

Qwen-VL (Bai et al., 2023)

VLM à résolution dynamique

Motif d'exclusion : Empreinte VRAM et temps de calcul incompatibles avec le matériel de bureau (8 Go VRAM).

Phi-3 Vision (Microsoft, 2024)

Modèle multimodal compact

Motif d'exclusion : Biais anglophone : hallucinations sur le vocabulaire foncier et cadastral français.

Modèles Cloud (GPT-4V, Claude)

Modèles propriétaires distants

Motif d'exclusion : Exclusion déontologique stricte : transfert tiers incompatible avec le secret professionnel (Loi 1946).

Principe directeur du cabinet

Chaque technologie écartée l'a été pour un motif opérationnel avéré : inadaptation au manuscrit, effet domino des erreurs, coût d'annotation disproportionné ou contrainte légale.

SOMMAIRE DE LA PARTIE

Architecture & Chaîne d'extraction IA

Pipeline souverain en 6 scripts Python : acquisition, segmentation et transcription

1

Architecture générale

les 6 étapes séquentielles du pipeline

2

Environnement technique

Python 3.12, PyTorch, CUDA, Ollama

3

Acquisition & scan

numérisation à plat A3/A0 et résolutions

4

Classification & dévers

détection de gabarit et transformée de Hough

5

Segmentation YOLOv8

découpage automatique des zones utiles

6

Prétraitement d'image

binarisation adaptative Sauvola et débruitage

7

Extraction textuelle & VLM

TrOCR, GLiNER et arbitrage MiniCPM-V

Architecture générale de la chaîne d'extraction

Les 6 modules séquentiels du pipeline de traitement

3.1 Conception du pipeline

- **Architecture modulaire** : 6 étapes spécialisées communiquant par formats standardisés.
- **Flux séquentiel optimisé** : Scan brut -> Scan orienté -> Zones découpées -> Texte transcrit -> JSON validé -> Versement.
- **Double mode d'usage** : Traitement en masse (batch) ou validation unitaire dans l'interface Streamlit.

6 modules

Architecture modulaire

Scripts Python dédiés

Batch & Web

Double mode

Ligne de commande ou Web

Diagramme des 6 étapes du traitement




Diagramme des 6 étapes du traitement des archives cadastrales

Environnement technique & Les 6 scripts Python

Organisation logicielle et responsabilités de chaque module

3.2 Les 6 scripts Python de la chaîne

- **1. dossier_parser.py** : Détection automatique des formats (PDF/TIFF) et découpe.
- **2. plan_classifieur.py** : Classification du gabarit et redressement de l'orientation.
- **3. spatial_extracteur.py** : Segmentation des zones d'intérêt métier par YOLOv8 Nano.
- **4. pretraitement.py** : Binarisation adaptative Sauvola et débruitage morphologique.
- **5. extraction_mots_cles.py** : Transcription EasyOCR/TrOCR et repérage GLiNER.
- **6. posttraitement.py** : Contrôle des 17 règles, filiation WFS et envoi API Géofoncier.

Stack technique & Moteurs IA

- **Langage & Runtime** : Python 3.12, PyTorch 2.3 avec accélération GPU CUDA.
- **Vision par ordinateur** : Ultralytics YOLOv8 Nano, OpenCV 4.9, Pillow.
- **Moteurs de lecture** : EasyOCR (formulaires) et TrOCR Large French (manuscrit).
- **Traitement NLP** : GLiNER DeBERTa-v3 pour l'extraction d'entités Zero-Shot.
- **Modèles multimodaux** : Ollama exécutant MiniCPM-V 2.6 en quantification 4-bit.

6 scripts

Architecture modulaire

Traitement unitaire ou lot

100 % local

Python 3.12 + GPU

Zéro appel Cloud

Déploiement en cabinet & Cartographie

- Environnement conda isolé garantissant la reproductibilité sur station géomètre.
- Interface Streamlit intuitive connectée aux flux WFS de la DGFIP.
- Intégration cartographique Folium/Leaflet pour contrôle visuel immédiat.

Acquisition & Numérisation des archives

Matériel de numérisation, protocoles et résolutions adaptées

3.3 Matériel & Protocoles de scan

- **Scanner à plat A3 professionnel** : Numérisation à plat des registres reliés sans risque de déchirement.
- **Scanner grand format A0 à rouleaux** : Réservé aux tirages ozalyd récents et plans sur calque non fragiles.
- **Résolution 300-400 DPI** : Résolution optimale pour capturer les déliés fins des écritures manuscrites.
- **Contrôle d'éclairage** : Éclairage LED direct évitant les reflets sur calques et papiers glacés.

300-400 DPI

Résolution optimale

Manuscrits anciens

200 DPI

Optimisation volume

Plans récents DAO

Numérisation haute résolution (Registre)

2 dossier	Date	Commune	Désignation de l'affaire	Donneur d'ordre	PRÉVISIO FACTURE
118/29 115/29	17/2/29	JUVINOS *	JA Jeckussant cheury Communi	J. CHASTAGNER	GRATUIT
119/29	24/4/29	LOVILLERIE *	JA CLENT / BOSTIAN	BOSTIAN.	PAYE CB
20/29	22/2/29	PROGES *	PLAN TOPO polid FONTIEN		inf. CA: le 13/4/29 8045 CCF le 1/8/29 c 78 18 8137.
121/29	22/2/29	PORTES LES VALENCE *	PLAN TOPO RETNOUANG Dim	RETNOUANG	GRATUIT
122/29	23/4/29	FIRMIN *	Lotissement GIRARD		RESTE DU 1513. 46 Mme RAVEL le 26-11-80 CLN: 6416540 PAYER le 12/11/1929
123/29	28/2/29	BUSSET *	PROPOSE FAMILIE POUCHET		
124/29	28/2/29	SE SERVIN	PROFILES ECOL		
125/29	4/3/29	Chapelle/Andremas *	DA DONToux / BILEYSE		Pays le 27-3-29 L'annonciat m. 352.9. 15-021 P. 56 le 24/4/29 n° 46557 P. 46 le 5/10/29 B.P. n° 58 03767.
126/29	12/5/29	UCEL *	DA RAINAUD / LEYNAUD-DELOY		
127/29	16/3/29	LENTILLERES *	JA. GIRON / Paul / SEUTER Felin	LEPUEZ de BURANGE	Pays le 25/11/29 C.C. n° 1346074

Numérisation haute résolution d'un registre ancien (double page A3)

Classification et orientation du document

Détection du type de pièce et redressement automatique (plan_classifieur.py)

3.4 Préparation géométrique

- **3 grandes familles de documents** : DMPC (formulaires d'arpentage), registres d'actes, plans et croquis.
- **Orientation automatique** : Détection 0°/90°/180°/270° par analyse Tesseract OSD.
- **Correction du dévers (skew)** : Transformée de Hough détectant les lignes pour redresser les biais ($\pm 5^\circ$).
- **Garantie amont** : Assure des boîtes englobantes parfaitement horizontales pour YOLO.

3 familles

Gabarits détectés


DMPC · Registres · Plans

$\pm 5^\circ$

Correction dévers

Transformée de Hough

Identification structurelle d'un DMPC



Identification structurelle d'un DMPC et de ses cartouches d'en-tête

Segmentation visuelle par YOLOv8

Localisation des cartouches, tableaux et signatures (spatial_extracteur.py)

3.5 Découpage ciblé des zones

- **Modèle YOLOv8 Nano spécialisé** : Entraîné sur les pièces graphiques et formulaires du cabinet.
- **Classes métier détectées** : Cartouche métadonnées, tableau d'assemblage, signatures, tampons.
- **Précision des boîtes englobantes** : Découpe nette des zones utiles avant transmission aux moteurs.
- **Robustesse documentaire** : Localise les zones même avec plis, taches ou tampons d'époque.

5 classes

Zones détectées


Cartouche, plan, tableau...

0,03 s

Vitesse d'inférence

Inférence ultra-rapide

Segmentation spatiale YOLOv8 annotée



Détection spatiale des éléments d'un DMPC par YOLOv8 (cartouche, plan, tableau)

Prétraitement de l'image pour l'OCR / HTR

Binarisation adaptative et amélioration du contraste ([pretraitement.py](#))

3.6 Nettoyage adaptatif du scan


- **Binarisation de Sauvola** : Seuil local calculé sur un voisinage : sépare l'encre sans pâtés.
- **Suppression du bruit de fond** : Filtres morphologiques éliminant plis, taches et transparences.
- **Égalisation d'histogramme CLAHE** : Renforce le contraste local sur les encres pâles ou décolorées.

Impact direct sur la reconnaissance

Un prétraitement adapté élimine 90 % des artéfacts d'arrière-plan et augmente drastiquement la précision des moteurs OCR et TrOCR sur documents anciens.

Démonstration du prétraitement avant/après

1. Image brute numérisée (inclinaison -3.5° et fond jauni)



2. Image traitée (Redressement Hough + Binarisation d Otsu)

COMMUNE DE SAINT PRIVAT
Section AL - Feuille 000 - Echelle 1/1000
Dossier No 1992-C-100001 (Archives GEO-SIAPP)

Démonstration du prétraitement : scan brut jauni vs image traitée binarisée

Extraction textuelle hybride & Arbitrage VLM

Association TrOCR + GLiNER + modèle Vision-Langage local (extraction_mots_cles.py)

3.7 Transcription & Arbitrage local

- **EasyOCR pour les formulaires** : Transcription rapide des cartouches dactylographiés imprimés.
- **TrOCR pour les écritures cursives** : Modèle francophone décodant les mentions manuscrites d'actes.
- **Extraction Zero-Shot (GLiNER)** : Reconnaissance des champs fonciers sans réentraînement sur mesure.
- **Arbitrage VLM sous Ollama** : MiniCPM-V 4-bit sollicité uniquement si confiance < 0,45.

La cascade de confiance

90 % des zones sont résolues rapidement par la combinaison TrOCR + GLiNER. Le modèle Vision-Langage n'intervient qu'en renfort ponctuel, préservant la cadence globale.

Cas réel d'arbitrage toponymique (VLM)

1. Registre d'archives manuscrit (Affaire 135/79)



Mention manuscrite : « Lachapelle /s/ AUBENAS »

Difficulté métier :
Abréviation locale difficile à comprendre sans être d'Ardèche.
Un OCR ordinaire extrait « Aubenas » ou hésite.

Statut : Alerte de cohérence levée (seuil < 0,45)

2. Arbitrage par l'IA locale (VLM & Base Ardèche)

Interprétation sémantique et toponymique :

« La Chapelle-sous-Aubenas »

- Code officiel INSEE validé : 07058 (100 %)
- Résolution contextuelle de l'abréviation « /s/ »
- Intégration du rayon d'activité historique du cabinet
- Validation automatique sans blocage opérateur

Bénéfice : traitement local souverain à 100 % (zéro fuite)

Arbitrage visuel d'une zone manuscrite complexe par le modèle Vision-Langage

SOMMAIRE DE LA PARTIE

Validation & Démonstration

Contrôles de cohérence, interface de relecture et versement sur Géofoncier

1

Fiabilisation

le moteur de 17 règles de contrôle cadastral

2

Interface de relecture

le dossier prérempli par l'outil

3

Démonstration en conditions réelles (vidéo composite)

4

Filiation parcellaire WFS & versement sur le portail Géofoncier

Fiabilisation : Les 17 règles de contrôle

Garantie de cohérence avant tout versement ([posttraitement.py](#))

Syntaxe (R1-R5)

Contrôle structurel

Format code INSEE (5 chiffres), sections cadastrales (1-2 lettres), dates au format ISO.

Géographie (R6-R11)

Validation spatiale

Vérification référentiel IGN communes Ardèche/Drôme, cohérence section/parcelle.

Métier foncier (R12-R17)

Contrôle cadastral

Présence obligatoire d'un objet (bornage, DMPC), filiation parcelles mères/filles.

Vert (Score $\geq 0,85$)

Validation automatique

- Tous les champs obligatoires extraits avec certitude.
- Règles syntaxiques et géographiques vérifiées.
- Dossier prêt à l'envoi API sans retouche humaine.

Orange (0,45 à 0,85)

Relecture recommandée

- Incertitude sur un champ spécifique (ex. écriture floue).
- Mise en valeur ciblée dans l'interface Streamlit.
- L'opérateur contrôle et valide d'un simple clic.

Rouge (Score $< 0,45$)

Saisie manuelle obligatoire

- Information manquante ou incohérence détectée.
- Blocage strict de tout versement vers Géofoncier.
- Sécurité absolue du référentiel juridique.

Interface de relecture : Le dossier prérempli

Visualisation de l'extraction automatique : champs, codes couleur, validation

4.2 Visualisation Streamlit

07110_000_160

0 / 1 documents validés

Format détecté : DMPC

À traiter (1 restant(s))

p1

Interface de contrôle de la qualité des extractions.

SAISIE & CORRECTION

Localisation

● COMMUNE
Généralement en haut ou centre ou dans le cartouche d'en-tête.
Joyeuse

INSEE: 07110 (100.0%)

● SECTION
En haut ou dans le tableau de filiation, souvent 1 ou 2 lettres (ex: AB).
AL

● FEUILLE
Souvent à côté de la section ou en haut à gauche.
1

● PARCELLES
Sur le plan lui-même.
['272 (Nouveau)', '271 (Nouveau)', '426 (Nouveau)', '434 (Ancien)']

Formulaire Streamlit prérempli automatiquement (Commune Joyeuse)

Contrôle & Validation opérateur

- **Affichage côte à côte** : L'image originale numérisée s'affiche en regard des champs extraits.
- **Validation en 1 clic** : Si tous les indicateurs sont au vert, l'opérateur valide en quelques secondes.
- **Modification directe** : En cas de doute (orange/rouge), correction d'un simple clic dans le formulaire.

Le rôle de l'humain dans la boucle

L'IA n'envoie jamais de données sans contrôle. Le professionnel reste le seul décideur et valide l'acte avant toute inscription ordinale.

Démonstration en conditions réelles

Du scan de l'archive papier au dossier prérempli prêt à verser sur Géofoncier

07110_000_160

0 / 1 documents validés
Format détecté : DMPC
À traiter (1 restant(s))
pl

Interface de contrôle de la qualité des extractions.

SAISIE & CORRECTION

Localisation

COMMUNE

Généralement en haut au centre ou dans le cartouche d'en-tête.
Joyeuse

INSEE: 07110 (100.0%)

SECTION

En haut ou dans le tableau de filiation, souvent 1 ou 2 lettres (ex: AB).
AL

FEUILLE

Souvent à côté de la section ou en haut à gauche.
1

PARCELLES

Sur le plan lui-même.
['272 (Nouveau)', '271 (Nouveau)', '426 (Nouveau)', '434 (Ancien)']


Interface Streamlit

Séquence : 1. Cas incomplet (relecture requise) • 2. Cas prérempli (filiation & pastille) • 3. Registres (extraction par lots)

Filiation parcellaire WFS & Versement Géofoncier

Génération des centroïdes Lambert-93 et inscription ordinale (Section 5.3 du mémoire)

4.4 Filiation parcellaire reconstituée



Arbre de filiation parcellaire reconstitué par interrogation WFS DGFIP

Procédure de versement ordinale

- **Requête WFS Cadastre DGFIP** : Interrogation en direct pour récupérer la géométrie exacte.
- **Reconstitution de filiation** : Liaison automatique entre parcelles mères et parcelles filles.
- **Calcul du centroïde Lambert-93** : Calcul des coordonnées (EPSG:2154) exigées par l'API Géofoncier.
- **Appel API endpoint rfuoge** : Transmission du payload JSON structuré et retour code 201 Created.

La pastille Géofoncier en temps réel

Dès réception du code 201, la pastille de bornage s'affiche instantanément sur la carte nationale Géofoncier, rendant l'archive visible à l'ensemble des géomètres-experts de France.

SOMMAIRE DE LA PARTIE

Bilan, Limites & Déontologie

Résultats opérationnels, contraintes physiques et conformité à la Charte IA OGE

1

Bilan opérationnel

gains de productivité et temps de traitement

2

Limites physiques et cas d'échec rencontrés sur le fonds

3

Perspectives d'évolution

enrichissement SIG et généralisation

4

Déontologie & Charte IA de l'Ordre des Géomètres-Experts (19 mai 2026)

Bilan opérationnel : Gains de productivité

Mesure des performances réelles sur les dossiers tests du cabinet

Méthode traditionnelle manuelle (25 min)

- **Recherche physique carton** : 15 minutes : déplacement, manipulation de cartons d'archives.
- **Saisie des métadonnées** : 7 minutes : déchiffre manuel des noms, communes, parcelles.
- **Contrôle cadastral** : 3 minutes : vérification manuelle sur le portail Géofoncier.
- **Bilan opérateur** : 25 minutes de temps opérateur mobilisé par dossier.

Chaîne automatisée IA (< 3 min)

- **Extraction automatique** : 45 secondes : YOLO + TrOCR + GLiNER en tâche de fond.
- **Relecture opérateur** : 1 minute 30 secondes : validation visuelle des pastilles vertes.
- **Versement API direct** : 15 secondes : appel REST et pastille instantanée Géofoncier.
- **Gain mesuré** : Division par 8 du temps de traitement (~9 800 heures économisées).

< 3 min

Temps / dossier
vs 25 min manuel

82 %

Dossiers parfaits
Sans retouche manuelle

x8

Gain productivité
Division du temps

Limites physiques et cas d'échec

Facteurs de dégradation matérielle affectant la reconnaissance


5.2 Facteurs d'échec matériel

- **Dégradations physiques du papier** : Plis marqués, déchirures, taches d'encre et jaunissement.
- **Écritures très cursives ou effacées** : Variabilité extrême des encres d'époque et abréviations locales.
- **Absence de parcelles dans le cadastre** : Cas où le remembrement a supprimé la référence historique.

Stratégie face aux échecs

Lorsqu'un document est trop altéré, le système alerte l'opérateur (pastille rouge) et bloque le versement. La décision revient toujours au géomètre-expert.

Document historique dégradé réel



Document foncier historique réel : plis, ratures manuscrites et tampons d'époque

Perspectives d'évolution du projet

Pistes d'amélioration technique et déploiement futur

Horizon 1 : Couplage DAO & SIG

Extraction vectorielle des sommets de bornage et génération de fichiers DXF pour intégration directe dans Covadis.

Horizon 2 : Authentification des signatures

Réseau de classification vérifiant les signatures et sceaux des prédécesseurs pour consolider la valeur juridique.

Horizon 3 : Déploiement inter-cabinets

Standardisation sous forme de logiciel libre pour les cabinets membres de l'Ordre des Géomètres-Experts.

DAO / SIG

Vectorisation automatique

Couplage Covadis

Mutualisation

Déploiement OGE

Fonds nationaux

Déontologie & Charte IA OGE (19 mai 2026)

Conformité du projet aux 4 principes directeurs de l'Ordre des Géomètres-Experts

1. Transparence

- Traçabilité complète de l'origine de chaque donnée extraite.
- Signalement visuel immédiat des champs vérifiés ou modifiés.
- Accès en un clic à l'image source originale haute résolution.
- **Garantie : aucune décision algorithmique occulte ou opaque.**

2. Protection des données

- Exécution 100 % locale sur station de travail au cabinet.
- Aucune image ni métadonnée transmise vers des serveurs tiers.
- Étanchéité souveraine conforme au secret professionnel ordinal.
- **Garantie : respect absolu de la confidentialité des clients.**

3. Traçabilité probante

- Conservation pérenne des scans originaux sans altération.
- Journalisation détaillée des validations humaines en base.
- Horodatage et archivage conformes aux exigences OGE.
- **Garantie : pleine opposabilité juridique des dossiers traités.**

4. Responsabilité professionnelle

- L'IA constitue une aide technique : elle ne décide jamais.
- Le géomètre-expert assume seul la validation finale des pièces.
- Maintien de la garantie intellectuelle sur les limites foncières.
- **Garantie : préservation intégrale du monopole de la loi de 1946.**

Conformité totale

Le projet s'inscrit rigoureusement dans le cadre déontologique fixé par l'Ordre le 19 mai 2026. L'outil valorise le patrimoine sans jamais substituer la machine à l'expertise du géomètre-expert.

CONCLUSION DU PROJET DE FIN D'ÉTUDES

Merci de votre attention

Place aux questions du jury

Outil 100 % local

Souveraineté des données et respect du secret
professionnel OGE

Gain de productivité x8

Validation mesurée sur 23 600 dossiers papier
(1959-2007)

Cadre déontologique

Conformité totale avec la Charte IA ordinale du 19
mai 2026

Adrien TRAVAILLÉ • adrien.travaille@insa-strasbourg.fr

Projet de Fin d'Études • Spécialité Topographie • INSA Strasbourg & Cabinet GEO-SIAPP